

UFPB

UNIVERSIDADE FEDERAL DA PARAÍBA
CENTRO DE CIÊNCIAS SOCIAIS APLICADAS
CIÊNCIAS DE DADOS PARA NEGÓCIOS
APRENDIZAGEM DE MÁQUINA SUPERVISIONADA

MARIA EDUARDA COSTA PEREIRA DE SOUZA
LETÍCIA SOUSA MOREIRA
MARINA ISABEL DE ASSIS MORAES ANDRADE

Maq-Larem: Locação com Tecnologia

PROFESSOR: ALÉSSIO TONY CAVALCANTI DE ALMEIDA

JOÃO PESSOA
2026

Relatório de Preparação dos Dados e Baseline de Machine Learning

Introdução

O projeto tem como objetivo desenvolver um experimento de Machine Learning voltado à previsão de cancelamento de clientes. Inicialmente, a proposta estava relacionada às necessidades da empresa Maqlarem. Entretanto, devido à ausência de acesso aos dados internos da organização até o momento da realização do trabalho, optou-se pela utilização de uma base pública para permitir o desenvolvimento das etapas de preparação dos dados e construção de um modelo preditivo.

A base selecionada foi a Telco Customer Churn, disponibilizada publicamente pela IBM. Ela contém informações de clientes de uma empresa do setor de telecomunicações e permite investigar características associadas ao cancelamento de serviços.

É importante destacar que os dados utilizados não pertencem à Maqlarem. Dessa forma, o experimento não representa uma análise dos clientes reais da organização, mas uma aplicação metodológica que poderá servir como referência para estudos futuros com dados da empresa

1. Contrato dos dados

1.1 Identificação e origem

- Base Utilizada:
- Telco Customer Churn- obtida por meio do repositório público da IBM no GitHub:

link do repositório:https://github.com/IBM/telco-customer-churn-on-icp4d

- O conjunto de dados apresenta informações cadastrais, características dos serviços contratados, tempo de permanência, valores cobrados e a ocorrência de cancelamento

1.2 Unidade de análise e granularidade

A unidade de análise é o Cliente. Cada registro representa um cliente e suas respectivas características registradas na base. A variável “customerID” identifica individualmente os registros.

A granularidade é, portanto, de um registro por cliente, não sendo organizada como uma série temporal de eventos sucessivos.

1.3 Variável-Alvo

A variável-alvo escolhida foi a Churn, que indica se o cliente cancelou o serviço ou não. Ela possui duas categorias: “Yes”, correspondente ao cancelamento, e “No”, correspondente à ausência de cancelamento.

O objetivo do experimento é investigar se as demais características disponíveis permitem identificar padrões relacionados à ocorrência de cancelamento.

1.4 Cobertura Temporal e Disponibilidade das Informações

A base não apresenta uma data individual de referência que permita determinar com precisão quando cada informação foi registrada em relação ao cancelamento. Por esse motivo, não é possível estabelecer um corte temporal rigoroso, ou garantir que todas as variáveis estivessem disponíveis antes da decisão que se pretende apoiar.

Essa limitação será considerada na análise de possíveis vazamentos de informação e na interpretação dos resultados do modelo.

1.5 Restrições de uso

Por se tratar de uma base pública de outra organização e de outro setor, os resultados deverão ser interpretados exclusivamente como experimentais. A aplicação do modelo à MaqLarem dependeria da obtenção de dados próprios, da avaliação de sua qualidade e da verificação de sua adequação à realidade operacional da empresa.

1.6 Atualização e Cobertura de Base

A base foi obtida no repositório público da IBM ("telco-customer-churn-on-icp4d") e acessada para este projeto no ano de 2026. A documentação original não especifica uma

frequência de atualização ativa, nem delimita a cobertura territorial exata ou a população demográfica específica, tratando-se de um conjunto de dados ilustrativos de uma empresa de telecomunicações norte-americana. Diante dessa ausência, registra-se como limitação o fato de que a base representa um retrato estático de clientes, impossibilitando análises baseadas em sazonalidade.

2. Auditoria e preparação dos dados

A auditoria inicial, teve como finalidade verificar a estrutura da base, a consistência dos registros e a existência de problemas que pudessem comprometer a análise.

A base original possui 7.043 registros e 21 colunas. Entre as verificações realizadas, foram analisados os tipos de dados, a distribuição da variável-alvo, os valores ausentes e a existência de duplicidades.

2.1 Valores ausentes e tratamento de TotalCharges

Durante a análise da variável “TotalCharges”, foram identificados 11 registros cujos valores não puderam ser convertidos para o formato numérico. A inspeção desses registros demonstrou que todos correspondiam a clientes com “tenure” igual a zero.

Considerando que esses clientes não apresentavam tempo de permanência registrado, foi adotada a decisão de substituir os valores ausentes de “TotalCharges” por zero. Essa decisão constitui uma hipótese de tratamento para o experimento e deverá ser documentada como tal, pois não é possível comprovar apenas com a base que o valor zero corresponde ao histórico financeiro real de cada cliente.

Após o tratamento, a variável não apresentou valores ausentes.

2.2 Padronização e Duplicidades

Foi criada uma cópia da base original para preservar os dados de origem. Em seguida, foram removidos espaços desnecessários dos nomes das colunas e dos valores textuais, além de realizar a conversão de “TotalCharges” para o formato numérico.

Após a limpeza, a base permaneceu com 7.043 registros e 21 colunas. Não foram identificadas linhas integralmente duplicadas nem identificadores de clientes duplicados

2.3 Distribuição da Variável-Alvo

- Clientes que não cancelaram (“No”): 5.174 registros, correspondentes a 73,46% da base
- Clientes que cancelaram (“Yes”): 1.869 registros, correspondentes a 26,54% da base

A distribuição demonstra um desequilíbrio entre as classes, pois os registros de clientes que não cancelaram são mais numerosos. Essa característica deverá ser considerada na avaliação do modelo, uma vez que uma métrica como a acurácia, analisada isoladamente, pode transmitir uma impressão excessivamente positiva do desempenho.

2.4 Relatório de Qualidade dos Dados

Variável/base	**Problema identificado**	**Decisão aplicada**	**Impacto/Validação**
TotalCharges	11 valores não numéricos	Substituição por zero	Sem ausências após o tratamento
customerID	Possibilidade de duplicidade	Verificação de unicidade	Nenhum ID duplicado identificado
Churn	Desequilíbrio entre classes	Preservar a distribuição e considerar na avaliação	73,46%- “No” 26,54%- “Yes”
Base completa	Possibilidade de linhas duplicadas	Verificação de duplicidades	Nenhuma linha duplicada identificada
Colunas textuais	Espaços desnecessários	Padronização dos textos	Confirmar validação no notebook

2.5 Validação da Base Processada

A base processada foi gerada com sucesso pelo notebook de auditoria e salva no diretório dados/processado/ sob o nome telco_churn_processado.csv. A base final manteve exatamente as mesmas dimensões da base bruta: 7.043 registros e 21 colunas. Não houve exclusão de nenhuma linha ou coluna; o único tratamento aplicado aos valores foi o preenchimento dos 11 registros ausentes em TotalCharges com o valor 0. A quantidade de chaves únicas (customerID) permaneceu em 7.043, comprovando a ausência de duplicações indesejadas durante o processamento.

3. Diagnóstico de vazamento de informação

O diagnóstico de vazamento de informação busca identificar variáveis que forneçam ao modelo informações que não estariam disponíveis no momento em que uma previsão real precisasse ser realizada.

Variável	Permitida?	Justificativa
Churn	Não	Representa o resultado que se pretende prever. Utilizá-la como entrada causaria vazamento do alvo
customerID	Não utilizada	É um identificador individual, não uma variável preditora escolhida para o experimento. Sua exclusão não caracteriza, por si só, vazamento
tenure	Condicional	Pode ser utilizada se representar o tempo de permanência conhecido antes da previsão
MonthlyCharges	Condicional	Pode ser utilizada se o valor mensal ja estiver disponível no momento da previsão
Contract	Condicional	Pode ser utilizada se representar a modalidade contratual vigente no momento da previsão
TotalCharges	Condicional	O valor acumulado pode conter informações posteriores ao momento em que a previsão deveria ocorrer.

3.2 Riscos Identificados e Decisões Adotadas

A variável Churn foi identificada como fonte de vazamento do alvo e não deverá ser utilizada como preditora. A variável TotalCharges apresenta risco de vazamento temporal, pois seu valor acumulado pode incluir informações posteriores ao momento da previsão. Para evitar vazamento de partição, os procedimentos de pré-processamento que exigem ajuste deverão utilizar exclusivamente os dados de treinamento. A ausência de datas individuais na base impede a verificação completa da disponibilidade temporal das variáveis, permanecendo como limitação do experimento.

- A variável `Churn` **foi excluída** das entradas (features - `X`) porque é o nosso Alvo (`y`).
- A variável `customerID` **foi excluída** do modelo por ser um mero identificador (poderia causar sobreajuste e não generalizar).
- As variáveis `TotalCharges` e `MonthlyCharges` **foram mantidas**, porém receberam tratamento contra vazamento através do `Pipeline`, aprendendo parâmetros exclusivamente no conjunto de Treino.

4. Estratégia de partição dos Dados

A estratégia de partição adotada foi a divisão aleatória estratificada (`stratify`). Esta escolha justifica-se pela ausência de datas individuais na base, o que inviabiliza uma separação cronológica estrita. A proporção utilizada foi de 60% para o conjunto de treinamento (4.225 registros), 20% para validação (1.409 registros) e 20% para o teste isolado (1.409 registros). O uso da estratificação foi crucial para garantir que a proporção desequilibrada da variável-alvo (73,46% sem cancelamento e 26,54% com cancelamento) fosse rigorosamente espelhada em todos os três conjuntos.

Essa divisão procura representar o cenário real no qual o modelo avaliará a base mensal ativa de clientes, buscando detectar quem apresenta perfil de cancelamento iminente. Como limitação, por não ser uma partição temporal, o modelo avalia registros "misturados" no tempo, dificultando a aferição exata do desempenho no futuro.

5. Pré-Processamento dos Dados

A base Telco Customer Churn apresenta variáveis numéricas e categóricas, exigindo tratamentos específicos para sua utilização no experimento.

Na preparação inicial, foram removidos espaços desnecessários dos valores textuais e realizada a conversão da variável TotalCharges para o formato numérico. Os 11 registros com valores ausentes nessa variável foram preenchidos com zero, considerando que apresentavam tenure igual a zero.

5.1 Transformações aplicadas

As variáveis numéricas utilizadas foram `tenure`, `MonthlyCharges` e `TotalCharges`. O tratamento para este grupo incluiu imputação de eventuais novos valores nulos pela mediana (`SimpleImputer(strategy='median')`) seguida da padronização de escala com `StandardScaler()`. As demais 16 variáveis atuaram como categóricas (ex: `InternetService`, `Contract`, `PaymentMethod`). Para elas, a imputação de nulos baseou-se na categoria mais frequente (moda) e a transformação em valores numéricos foi feita através de codificação dummy (`OneHotEncoder`), descartando a primeira coluna em casos estritamente binários (`drop='if_binary'`). Todos esses parâmetros (médias, medianas e categorias mais frequentes) foram aprendidos **exclusivamente com os dados de treinamento**, sendo apenas aplicados na validação e teste. A principal limitação é que categorias inéditas nos dados de teste serão ignoradas (`handle_unknown='ignore'`), o que pode perder alguma informação nova, mas garante que o modelo não falhe no cenário de produção.

5.2 Controle de vazamento no pré-processamento

O controle de vazamento foi garantido pelo uso de um `Pipeline` aninhado dentro de um `ColumnTransformer` (via biblioteca Scikit-Learn). A operação de ajuste (`fit_transform`) foi rigorosamente limitada ao conjunto de treinamento (`X_train`), restringindo-se os conjuntos de validação e teste apenas à operação de transformação

(`transform`). Como evidência da robustez contra vazamento de partição, a matriz gerada demonstrou consistência absoluta, resultando em exatas 40 features em todos os três conjuntos (treino, validação e teste).

6. Baseline e Avaliação Inicial

6.1 Baseline Trivial

Considerando a distribuição da variável Churn, a classe majoritária corresponde aos clientes que não cancelaram o serviço (No), representando 73,46% dos registros da base original.

O baseline trivial implementou a regra ingênua fundamentada na classe majoritária, prevendo a classe "0" (ausência de cancelamento / *No Churn*) para 100% dos clientes analisados. No conjunto de validação, este modelo alcançou uma acurácia de 73,46% (0.7346). Trata-se de uma métrica matematicamente esperada devido ao desequilíbrio da base, mas que mascarou uma falha total na identificação de churn: a precisão e o recall para a classe de cancelamento (1) foram de exatos 0%.

6.2 Baseline Operacional

A regra operacional priorizou clientes fundamentada na seguinte hipótese de negócio: clientes com contratos mensais (`Contract == 'Month-to-month'`) e mensalidades acima da média estipulada (`MonthlyCharges > 65.0`) apresentam maior probabilidade de cancelamento (classe 1). No conjunto de validação, esta regra apresentou uma acurácia global de 74,45% (0.7445). Diferentemente do modelo trivial, esta regra conseguiu identificar com sucesso 64% de todos os clientes que efetivamente cancelaram o serviço (Recall da classe 1 = 0.64), alcançando uma precisão de 52% nos casos apontados como churn. Essa regra operacionaliza a decisão definida no Canvas ao fornecer à equipe de retenção um filtro primário focado nos clientes mais propensos ao cancelamento devido a alta cobrança associada a contratos flexíveis.

6.3 Métrica de avaliação

Embora a Acurácia seja uma métrica primária comum, ela se demonstrou ineficaz para o baseline trivial devido ao desequilíbrio das classes. Dessa forma, a métrica secundária e principal para a comparação de performance da detecção de cancelamentos é o **Recall da classe 1** (Sensibilidade), pois na lógica de negócios definida no Canvas, o custo de um Falso Negativo (deixar um cliente ir embora sem tentar retê-lo) impacta diretamente a receita. O baseline operacional provou sua superioridade em relação ao trivial ao registrar um recall considerável (64% contra 0%), além de melhorar a acurácia base. Portanto, o **Baseline Operacional** será a referência (régua de performance) para as futuras aplicações dos modelos preditivos de Inteligência Artificial.

7. Limitações

A principal limitação do projeto é a utilização de dados de telecomunicações para investigar um problema que surgiu no contexto de outra organização. As relações identificadas na base pública podem não representar os fatores associados ao cancelamento de contratos da MaqLarem.

Além disso, a ausência de uma data referência para cada registro limita a avaliação temporal do problema. A distribuição dos dados entre treino, validação e teste deverá ser documentada, e os resultados serão interpretados como uma avaliação experimental, não como comprovação de desempenho em uma aplicação real.

A utilização futura deste tipo de solução na MaqLarem dependerá da disponibilidade de dados próprios, da definição do momento em que a previsão seria realizada e da validação dos resultados com informações compatíveis com o processo decisório da empresa. Adiciona-se também como limitação a premissa adotada no preenchimento de dados nulos da variável `TotalCharges` com o valor zero, e a impossibilidade do `OneHotEncoder` ler categorías totalmente inéditas na etapa de teste (handle_unknown='ignore').

8. Declaração do Uso de IA Generativa

Durante o desenvolvimento do projeto, foi utilizada a ferramenta ChatGPT, desenvolvida pela OpenAI, como apoio à organização e revisão textual do relatório, além de auxiliar na compreensão e no tratamento dos dados durante a implementação dos códigos.

Na documentação, a ferramenta contribuiu com sugestões de estruturação e redação das seções metodológicas. Na etapa de programação, foi utilizada para esclarecer dúvidas sobre variáveis e dados menos familiares à equipe, orientar procedimentos de manipulação e tratamento dessas informações e auxiliar na compreensão de sua aplicação no código.

Anexos e Documentação Complementar

Repositório do projeto: https://github.com/M-Eduarda-Souza/projeto-AMS-VD

Notebook principa**l:** notebooks/auditoria_baseline.ipynb